



APLICACIONES INTELIGENTES

Nombre: Rua Echalar Juan Manuel

C.U: 111-394

Carrera: Ingeniería en Ciencias de la Computación

Modelos de difusión aplicados a la generación de firmas

I. Antecedentes.

La firma manuscrita es un signo personal utilizado como prueba de autenticidad y aprobación en documentos de valor legal y contractual.

En el ámbito de la aplicación de modelos de difusión a la generación de firmas no hay investigaciones que se ocupen específicamente de esta cuestión, es decir, un modelo que genere diseños de firmas. A pesar de esto, existen indagaciones en asuntos y problemas cercanos, como modelos aplicados a la generación de firmas 3D o técnicas de computer vision en la verificación de firmas manuscritas.

En el primer caso, la generación de firmas 3D se aborda en el artículo "Synthesis of 3D On-Air Signatures with the Sigma-Lognormal Model". Este trabajo presenta un enfoque innovador para generar firmas digitales en 3D de manera realista. Utilizando un modelo basado en patrones naturales del movimiento humano, el sistema es capaz de recrear no solo la forma de una firma, sino también su velocidad y trayectoria, imitando así el proceso de escritura real. Además, permite enriquecer firmas existentes con información de movimiento y generar copias sintéticas de firmas auténticas. Los experimentos muestran que estas firmas sintéticas pueden usarse para entrenar sistemas de autenticación con resultados similares a los obtenidos con firmas reales, lo que demuestra el potencial de esta tecnología para mejorar la seguridad y el desarrollo de nuevos métodos de verificación. Aunque este estudio se centra en la generación de firmas 3D, los métodos y resultados presentados ofrecen ideas relevantes para inspirar técnicas que, en un entorno 2D, puedan generar imágenes de firmas a partir de datos básicos como las iniciales del usuario.

En el segundo caso, se exploran las técnicas de computer vision aplicadas a la verificación de firmas manuscritas en el estudio "Usando técnicas de visión por computador para la validación de firmas manuscritas". Este trabajo se enfoca en el desafío de determinar si dos firmas corresponden a la misma persona, a pesar de la variabilidad inherente en cada realización de la misma firma y de la pérdida de información dinámica al capturar firmas de forma estática. Para abordar esta problemática, se emplean técnicas de preprocesamiento de imágenes, algoritmos de aprendizaje automático y redes neuronales convolucionales que permiten extraer características discriminativas de la escritura. Los resultados obtenidos resaltan la efectividad de estos métodos en la clasificación entre firmas genuinas y falsificadas, proporcionando una solución robusta para la verificación de identidad. Este enfoque es de especial interés para proyectos que buscan generar firmas, ya que el conocimiento obtenido sobre la extracción y análisis de rasgos distintivos puede contribuir al diseño de modelos generativos que aseguren la autenticidad y coherencia del trazo producido a partir de las iniciales.

II. Problemática.

Muchas personas carecen de una firma propia y, en su lugar, simplemente escriben su nombre en trámites oficiales. Esta ausencia de un diseño distintivo puede deberse a diversos factores, como la falta de hábito en el uso de firmas, la dificultad para desarrollar un trazo estilizado o la falta de asesoramiento en la creación de una firma personalizada. A nivel administrativo y social, esto puede generar inconvenientes, ya que una firma fácilmente replicable o sin un diseño único puede comprometer la seguridad y autenticidad de documentos firmados.

Las firmas cumplen una función legal, sirven como prueba de identidad y autenticidad en documentos oficiales, contratos y transacciones, desempeñando un papel clave en la seguridad jurídica y la confianza social. También reflejan la personalidad de quien las usa. A pesar de la existencia de métodos tradicionales para diseñar firmas, como la caligrafía personalizada o el asesoramiento de expertos, no se puede dar abasto a todas las personas debido al costo o tiempo que requiere el diseño de una firma.

El problema principal radica en que muchas personas carecen de una firma distintiva, debido a la falta de tiempo y asesoramiento, lo que puede comprometer la autenticidad de documentos debido a su fácil falsificación.

III. Abordaje.

Desarrollar un modelo de inteligencia artificial desde cero para generar firmas digitales es un desafío enorme, ya que requiere mucha potencia de cómputo, grandes cantidades de datos y mucho tiempo de entrenamiento. Por eso, en lugar de crear un modelo completamente nuevo, una alternativa más eficiente es aprovechar modelos ya existentes, como Stable Diffusion, que han sido optimizados y están disponibles en código abierto para su modificación.

Sin embargo, usar directamente un modelo preentrenado no es tan simple, ya que estos modelos fueron diseñados para generar imágenes generales y no firmas. Por ejemplo, si se introduce la palabra "CASA", el modelo probablemente generará una imagen de una vivienda en lugar de un diseño de firma con esas letras.



Imagen generada por el modelo con la entrada "PAN"



Imagen generada por el modelo con la entrada "PAN"

Para lograr que el modelo genere firmas en lugar de imágenes genéricas, es necesario hacerle algunos ajustes internos. En primer lugar, se debe modificar la parte encargada de interpretar el texto para que entienda correctamente las iniciales y no las relacione con

objetos comunes. Luego, se debe adaptar el proceso de creación de imágenes, congelando algunas partes del modelo para conservar el conocimiento útil y modificando otras para que aprenda a enfocarse en los rasgos específicos de las firmas.

Después de estos ajustes, el modelo aún no podrá generar firmas correctamente, pero habrá eliminado las asociaciones previas con imágenes irrelevantes. En este punto, se podrá entrenar con un nuevo conjunto de datos compuesto por aproximadamente 1500 imágenes de firmas junto con sus iniciales. Estas imágenes se obtendrán de bases de datos existentes y también de ejemplos creados manualmente.

Con este proceso, el modelo aprenderá a interpretar correctamente las iniciales proporcionadas y a generar firmas estilizadas que correspondan con las iniciales del usuario.

IV. Objetivos.

Objetivo Principal

Desarrollar un modelo de difusión capaz de generar firmas personalizadas a partir de las iniciales del usuario, asegurando una correspondencia mínima del 90% entre las iniciales proporcionadas y el diseño de la firma resultante. Además, la firma generada deberá cumplir criterios de estilización y fluidez que reflejen la naturalidad de una firma manuscrita.

Objetivos Específicos

- a) Revisar el marco teórico y metodológico respecto al estudio de las firmas. Tanto la caligrafía como la Rúbrica son disciplinas clave en el diseño de una firma. La primera se ocupa de la letra, es decir la forma, la inclinación, la legibilidad y el estilo. La segunda se centra en los adornos u ornamentos que acompañan a los caracteres.
- b) Consultar e indagar sobre las aplicaciones e investigaciones de la inteligencia artificial en la generación de firmas o áreas similares como la generación de texto manuscrito. Ver las técnicas implementadas, los modelos desarrollados y el estado del arte.
- c) Desarrollar y ajustar un modelo basado en *Stable Diffusion* para la generación de firmas, aplicando técnicas como la congelación de capas específicas (*Text Encoder*, *VAE*, *DownBlocks* y *MidBlock* de *UNet*), reinicialización de capas de atención y reentrenamiento de la capa de salida para garantizar que las imágenes generadas representen firmas estilizadas a partir de las iniciales proporcionadas.

- d) Validar el modelo y su implementación en una interfaz de usuario, evaluando la precisión de la correspondencia entre entrada y salida, la coherencia del diseño de las firmas generadas y la experiencia de usuario en la interacción con la herramienta, asegurando su funcionalidad y facilidad de uso.

V. Fundamentos Teóricos.

a) Caligrafía y escritura.

La firma como marca personal estilizada tiene sus fundamentos en el área de la escritura manual y la caligrafía. Gerrit Noordzij, en su libro “The stroke theory of writing” menciona algunos puntos referidos a la escritura manual, que sin embargo, considero extrapolables al diseño y escritura de firmas, estos son:

- “Un trazo es la huella ininterrumpida de un instrumento sobre el plano de escritura”, lo que indica que todo trazo nace de un movimiento continuo, controlado y significativo.
- “Cada punto en un contorno tiene su contraparte en el otro contorno. Este par de puntos es el contrapunto del trazo”, lo cual subraya la estructura interna del trazo y su equilibrio visual.
- “Pequeños cambios en la orientación del contrapunto [...] y cambios en el tamaño del contrapunto [...] influyen en gran medida en la impresión que causa una pieza escrita y son un factor importante en el análisis de manos individuales”, lo que resalta cómo las variaciones mínimas dan carácter único a cada firma.

En base a esto podemos establecer que una firma estilizada no depende solo del diseño visual, sino del control del trazo, la presión, la herramienta empleada y las variaciones sutiles que, en conjunto, construyen una identidad gráfica personal y reconocible.

A pesar de que estos rasgos (control, contrapuntos, contornos grosor del trazo, etc) son el resultado de las herramientas físicas que se usan para hacerlos (pluma, bolígrafo, tinta, papel, habilidad del que firma), persisten en su digitalización, pues la escritura digital, como fuentes o firmas, depende de los mismos rasgos. El dominio y control de todas estas propiedades del trazo es lo que cualquier mecanismo (humano o máquina) debe intentar conseguir para tener una firma estilizada, natural y compleja.

b) Inteligencia artificial aplicada a la generación de firmas

A pesar de que no hay muchas tentativas directas para generar imágenes de firmas en el campo de la inteligencia artificial, sí existen algunos intentos de aplicar machine learning a la generación de imágenes, aunque no como fin principal, sino para crear datasets sintéticos orientados a entrenar modelos de reconocimiento de firmas.

Por ejemplo, Victor K.S.L. Melo, en su trabajo *Deep learning approach to generate offline handwritten signatures based on online samples*, nos expone que mediante el uso de redes neuronales convolucionales se puede convertir firmas online en firmas offline sintéticas, lo cual permite ampliar los conjuntos de datos de entrenamiento y mejorar el rendimiento de los sistemas de verificación de firmas.

Por su parte, Sandesh Kandel, en su aproximación descrita en *Advancing Security: Machine Learning-Based Signature Forgery Detection in Document Authentication Systems*, desarrolla un sistema que utiliza machine learning y CNN para detectar falsificaciones en firmas, implementando conceptos de paralelización para optimizar tanto la eficiencia como el rendimiento en la autenticación de documentos.

En cuanto a modelos de difusión, si bien no hay un trabajo que se dedique a la generación de firmas, es de conocimiento general que Stable Diffusion XL puede generar imágenes de textos, e incluso firmas, aunque con claras limitaciones debido a que no es un modelo específico para esta tarea.

VII. Metodología

a. Sustento metodológico

El presente trabajo se fundamenta en la aplicación de modelos de difusión (diffusion models) adaptados para la generación de firmas digitales a partir de las iniciales del usuario. La metodología se apoya en la utilización y ajuste de modelos preentrenados (como Stable Diffusion) para generar imágenes específicas, mediante la congelación y reinicialización selectiva de capas, con el objetivo de transformar la generación de imágenes genéricas en una tarea especializada en la creación de firmas estilizadas.

b. Técnicas de recolección de datos

Para la construcción del dataset de 10,900 firmas se emplearon dos metodologías complementarias:

Firmas Reales Procesadas (250 muestras)

Las firmas auténticas fueron recopiladas manualmente de diversos sitios web y procesadas mediante:

- Eliminación del fondo, conservando únicamente el trazo de la firma
- Aplicación de fondo blanco uniforme
- Etiquetado con el nombre de la persona correspondiente

Generación Sintética (10,650 muestras)

El grueso del dataset se generó artificialmente utilizando Canvas HTML5 mediante dos enfoques:

Generación Algorítmica de Trazos Ornamentales

Se implementaron funciones de curvas Bézier con componentes aleatorios:

- **Curvas cúbicas:** cubicBezier(p0, p1, p2, p3, steps = 100, noiseIntensity = 0)
- **Curvas cuadráticas:** quadraticBezier(p0, p1, p2, steps = 100, noiseIntensity = 0)

Estas funciones incorporan variabilidad estocástica para simular la naturaleza irregular de los trazos manuscritos, generando elementos ornamentales característicos de firmas reales.

Generación Manual y Tipográfica

- **Trazos manuales:** Creación directa usando mouse sobre Canvas para patrones únicos
- **Fuentes especializadas:** Utilización de tipografías que emulan escritura manuscrita:

.Brittany-Signature.ttf

Allura-Regular.ttf

Taken by Vultures Demo.otf

Antro_Vectra.otf

BridgetLily.otf

Hathem_Bosteem.ttf

c. Materiales & herramientas

i. Arquitectura software desarrollado:


Se ha desarrollado un pipeline de entrenamiento basado en Diffusers de Hugging Face, integrando módulos de procesamiento de imágenes, ajuste de hiperparámetros y reinicialización de componentes del modelo.

ii. Esquema y descripción de componentes del software:

Servidor: Gestiona las solicitudes del cliente, recibe los datos del usuario (nombre y apellido) los procesa y los envía como prompt al modelo, y devuelve la imagen generada.

Modelo y Pipeline de generación: Encapsula el modelo de difusión, encargado de interpretar el prompt y generar la firma. (Véase anexos 1.0).

Interfaz de usuario: Permite la introducción de iniciales y visualización de las firmas generadas.



Leyenda de Componentes

- Capa de Presentación (Frontend)
- Capa de Aplicación (Backend)
- Capa de Modelo (IA/ML)

iii. Esquema y descripción de componentes de hardware:

GPU: Utilizada para el entrenamiento y la inferencia (ej. NVIDIA con soporte para CUDA y FP16) el modelo T4 ofrecido por Google Colab en su versión gratuita.

CPU: Soporte para preprocesamiento de datos y ejecución de scripts auxiliares.

Almacenamiento: Espacio proporcionado por HuggingFace para guardar modelos, checkpoints y el dataset (incluyendo versiones en disco del dataset y de los modelos

entrenados).

iv. Esquema y descripción de modelos o componentes inteligentes (esquemas y/o gráficas):

Modelo Base: Stable Diffusion (modelo preentrenado “segmind/small-sd”), adaptado para la tarea de generación de firmas.

Componentes del modelo:

UNet: Para el proceso de difusión y generación de imágenes.

Text Encoder (CLIP): Encargado de interpretar y codificar el prompt.

VAE: Autoencoder que decodifica el espacio latente a imágenes finales.

Se han generado gráficas de arquitectura que muestran la interacción entre estos componentes, detallando las capas “congeladas” y las que se reentrenan.

v. Valores de parámetros e hiperparámetros aplicados:

Resolución: 512 píxeles.

Se buscó una resolución intermedia para mantener un equilibrio entre calidad de imagen y bajo coste de cómputo al entrenar y generar imágenes.

Batch size: 1 (debido a limitaciones de GPU).

Gradient accumulation steps: 128.

Para que el modelo pueda procesar varios ejemplos en el entrenamiento antes de ajustar los pesos

Learning rate: 2e-05.

Tras distintas pruebas, es el que mejores resultados dio.

Max grad norm: 1.

Mixed precision: fp16.

Precisión mixta para reducir el consumo de ram.

Número de pasos de entrenamiento: 9200

debido a los límites de tiempo y de uso de Colab

vi. Técnicas de depuración aplicadas:

Gradient Checkpointing: Para reducir el uso de memoria durante el entrenamiento.

Uso de Exponential Moving Average (EMA): Suavizado de actualizaciones para estabilizar la convergencia.

Verificación de integridad del dataset: Mediante acumuladores para revisar la normalización de píxeles.

Depuración del pipeline: Ejecución de tests unitarios en componentes críticos como el Text Encoder y el módulo de inferencia personalizada (MyPipe).

vii. Especificaciones técnicas:

Framework: Hugging Face Diffusers.

Lenguaje: Python 3.

Librerías adicionales: PyTorch, Transformers, Accelerate, Matplotlib, Requests.

Sistema operativo: Linux (configuración en entorno de Google Colab).

viii. Lenguajes de programación, frameworks, entre otros:

Lenguaje de programación: Python.

Frameworks: Diffusers, PyTorch, Transformers.

Herramientas de gestión de datasets: Hugging Face Datasets.

Herramientas de visualización: Matplotlib, IPython.display.

ix. Otros aspectos importantes:

Uso de técnicas de reinicialización de capas específicas (por ejemplo, la capa de salida del UNet y las capas de atención cruzada) para adaptar el modelo a la tarea específica.

Implementación de una interfaz de usuario que valida el formato del prompt y modifica dinámicamente las entradas para asegurar una generación coherente de firmas.

d. Plan de trabajo

El plan de trabajo se ha estructurado en las siguientes fases:

1. Revisión bibliográfica y definición del marco teórico:

Estudio de la teoría de trazos y caligrafía (con base en obras como “The stroke: Theory of writing” de Gerrit Noordzij).

Revisión de investigaciones en la generación de firmas y en el uso de modelos de difusión.

2. Preparación y preprocesamiento del dataset:

Carga, análisis y normalización del dataset de firmas.

3. Desarrollo y ajuste del modelo:

Adaptación de un modelo preentrenado (Stable Diffusion) mediante técnicas de congelación y reinicialización de capas.

Entrenamiento del modelo con los parámetros definidos.

4. Implementación de la interfaz de usuario y pruebas de inferencia:

Desarrollo de un módulo (MyPipe) que gestiona el prompt y la generación de imágenes.


Validación de la generación de firmas a partir de diferentes inputs.

5. Evaluación y análisis de resultados:

Evaluación de la correspondencia entre las iniciales y la firma generada, utilizando métricas de rendimiento y análisis visual.

6. Documentación y publicación de resultados.

e. Cronograma.



Resultados y Conclusiones

a. Dataset

i. Descripción y preprocesamiento realizado:

Se formó un dataset de 1500 firmas manuscritas, ya procesadas como se indicó en párrafos previos. Se documentaron evidencias visuales del estado del dataset antes y después del preprocesamiento, mostrando la mejora en la homogeneidad y calidad de las imágenes.

ii. Conjunto de entrenamiento, evaluación y validación:

Se definieron splits de datos para entrenamiento y, en su caso, para evaluación y validación, garantizando la representatividad y diversidad de las muestras.

iii. Información adicional:

Se ha realizado un análisis estadístico del dataset, con la medición de la media, desviación estándar, y rangos de píxeles, lo que permitió ajustar los parámetros de normalización y mejorar la calidad de la imagen final.

ii. Exactitud:

Se obtuvo una exactitud superior al 60% en la generación correcta de firmas que corresponden a las iniciales proporcionadas.

iii. Pérdida

Al inicio del entrenamiento el modelo tenía una pérdida de loss = 0.0832, luego de 9200 pasos de entrenamiento la pérdida es de loss = 0.00527

iv. FID (Frechet Inception Distance)

FID (Frechet Inception Distance) es una métrica que mide qué tan similares son dos conjuntos de imágenes. Se aplicó para comparar las imágenes reales del dataset con las generadas por el modelo, la siguiente tabla ilustra los valores que maneja FID y el resultado obtenido por el modelo.

Rango FID	Interpretación
$FID < 10$	Alta similitud: las imágenes generadas son casi indistinguibles de las reales.
$10 \leq FID < 50$	Similitud media: se perciben diferencias leves entre imágenes reales y generadas.
$FID \geq 50$	Similitud baja: diferencias evidentes, poca correspondencia entre reales y generadas.
Puntuación FID del modelo:	56.7

v. LPIPS (Learned Perceptual Image Patch Similarity)

Esta métrica nos indica la diversidad de las salidas o imágenes generadas para un mismo prompt o entrada que recibe el modelo, en una escala de 0 a 1, donde un valor bajo indica poca diversidad (imágenes similares) y un valor alto indica mayor diversidad (imágenes más distintas).

LPIPS del modelo: 0.0725

c. Resultados de aplicación y utilización

El modelo ha sido implementado en una interfaz de usuario que permite la entrada de iniciales y la generación en tiempo real de firmas estilizadas. Se han realizado pruebas de inferencia utilizando prompts con distintos formatos, demostrando la capacidad del modelo para ajustarse y generar resultados coherentes y visualmente atractivos. La integración de la técnica de congelación de capas y la reinicialización de componentes críticos ha sido decisiva para mantener la fidelidad del trazo en la firma generada.

d. Coincidencia de los resultados con los objetivos planteados

Los resultados obtenidos confirman que el modelo de difusión ajustado debe continuar con su entrenamiento y proyección según el cronograma, pues el objetivo principal de generar firmas personalizadas a partir de las iniciales, alcanzando una correspondencia mínima del 90% y logrando una estilización que imita la naturalidad de una firma manuscrita aun no se ha logrado (60% actualmente). Además, la combinación de técnicas de preprocesamiento, ajuste de hiperparámetros y estrategias de depuración ha permitido alcanzar un rendimiento robusto y reproducible, validando la viabilidad del enfoque propuesto para la generación de firmas digitales.

Imagen 1. Firma generada para el prompt “Cecilia Paredes”



VIII. Bibliografía.

Facultat d'Informàtica de Barcelona (FIB), Universitat Politècnica de Catalunya (UPC) – BarcelonaTech. (2019, 4 de julio). *Usando técnicas de visión por computador para la validación de firmas manuscritas* [Trabajo final de Máster, Master en Enginyeria Informàtica (MEI)].

Ferrera, M. A., Diaza, M., Carmona-Duarte, C., Quintana, J. J., & Plamondon, R. (2024, 31 de enero). *Synthesis of 3D on-air signatures with the Sigma-Lognormal model*. Instituto Universitario para el Desarrollo Tecnológico y la Innovación en Comunicaciones (iDeTIC), Universidad de Las Palmas de Gran Canaria; Ecole Polytechnique, University of Montreal.

Noordzij, G. (2019). *The stroke: Theory of writing* (P. Enneson, Trans.). Uitgeverij de Buitenkant. (Trabajo original publicado en 1985)

Melo, V. K. S. L., Bezerra, B. L. D., Impedovo, D., Pirlo, G., & Lundgren, A. (2019). Deep learning approach to generate offline handwritten signatures based on online samples. IET Biometrics. <https://doi.org/10.1049/iet-bmt.2018.5091>

Kandel, S. (2023). Advancing security: Machine learning-based signature forgery detection in document authentication systems. International Journal for Multidisciplinary Research, 5(6), Article IJFMR23069039.

IX. Anexos.

PipeLine del modelo generador de Firmas

